



T.C.
DOKUZ EYLÜL ÜNİVERSİTESİ
FEN FAKÜLTESİ
İSTATİSTİK BÖLÜMÜ

YÖNLENDİRİLMİŞ GRUP ÇALIŞMASI DÖNEM SONU
RAPORU

BETÜL TEMEL

İÇİNDEKİLER

1. ÖZET

2. GİRİŞ

2.1. Çalışmanın Amacı ve Kapsam

2.2. Veri Setinin Kaynağı ve Manipülasyon Süreci

3. VERİ SETİ VE DEĞİŞKEN TANIMLARI

3.1. Hedef Değişken ve Sınıflandırma Mantığı

3.2. Sayısal ve Kategorik Öznitelikler

4. VERİ ÖN İŞLEME SÜREÇLER

4.1. Eksik Veri Analizi ve KNN Imputation Uygulaması

4.2. Veri Ölçeklendirme: Z-Score Standartlaştırması

5. DENETİMLİ ÖĞRENME MODELLEMELERİ

5.1. Lojistik Regresyon: Olasılıksal Yaklaşım ve Katsayı Analizi

5.2. Karar Ağaçları (CART): Kural Bazlı Sınıflandırma ve CP Analizi

5.3. Random Forest: Gini Importance ve OOB Hata Analizi

5.4. Gradient Boosting Machines (GBM): Etkileşim Isı Haritaları ve H-İstatistiği

5.5. XGBoost: Gain Metriği ve İleri Düzey Öğrenme Eğrileri

5.6. LightGBM: Kalibrasyon Eğrisi ve Nihai Performans

6. BOYUT İNDİRGEME ÖNCESİ EN İYİ MODEL SEÇİMİ

7. BOYUT İNDİRGEME YÖNTEMLERİ VE KARŞILAŞTIRMA

7.1. PCA (Temel Bileşenler Analizi) ve Bilgi Kaybı Değerlendirmesi

7.2. LDA ve PLS-DA Yaklaşımları

8. BOYUT İNDİRGEME SONRASI EN İYİ MODELİN SEÇİLMESİ

9. SONUÇ VE TARTIŞMA

9.1. İstatistiksel Çıkarımlar

9.2. Sosyolojik Bulgular ve Politika Önerileri

10. KAYNAKÇA

1. ÖZET

Bu çalışma, Avrupa Sosyal Araştırması (ESS) verilerini kullanarak göçmenlerin genel mutluluk düzeylerini denetimli makine öğrenmesi algoritmaları ile sınıflandırmayı ve mutluluk üzerinde etkili olan sosyo-ekonomik, demografik ve algısal faktörleri istatistiksel olarak modellemeyi amaçlamaktadır. Proje kapsamında, bir dönem boyunca teorik ve pratik olarak incelenen tüm denetimli öğrenme yöntemleri tek bir veri seti üzerinde entegre edilerek karşılaştırmalı bir analiz sunulmuştur.

Veri ön işleme aşamasında, orijinal veri yapısının ve varyansının bozulmaması adına eksik gözlemler KNN (K-Nearest Neighbors) Imputation yöntemi ile doldurulmuştur. Boyut indirgeme ve mesafe tabanlı algoritmaların gereksinimleri doğrultusunda, veriler Z-Score yöntemi ile standartlaştırılarak analize hazır hale getirilmiştir.

Modelleme süreci; veri setinin temel istatistiksel yapısını anlamak amacıyla Lojistik Regresyon ve kural tabanlı Karar Ağaçları (CART) algoritmaları ile başlatılmıştır. Takip eden aşamalarda Random Forest, Gradient Boosting Machines (GBM), XGBoost ve LightGBM gibi ileri düzey topluluk (ensemble) yöntemleri kurularak tahmin performansları optimize edilmiştir. Algoritmaların ürettiği sonuçları SHAP değerleri ve Partial Dependence Plots (PDP) kullanılarak özniteliklerin marjinal ve etkileşimsel katkıları derinlemesine incelenmiştir. Ayrıca, Temel Bileşenler Analizi (PCA) ve LDA, PLS gibi boyut indirgeme yöntemlerinin model performansı üzerindeki etkileri test edilmiştir.

Analizler sonucunda, yüksek tahmin gücü, kalibrasyon başarısı ve non-lineer yapıları yakalama kabiliyeti ile **LightGBM**, çalışmanın şampiyon modeli olarak belirlenmiştir. PCA gibi boyut indirgeme yaklaşımlarının, veri setindeki orijinal değişkenlerin (özellikle "ayrımcılık algısı" gibi saf özniteliklerin) açıklayıcılığını seyrelterek bilgi kaybına neden olduğu istatistiksel olarak kanıtlanmıştır.

Sosyolojik çıkarımlar açısından değerlendirildiğinde; yüksek "toplumsal güven" ve "sosyal etkileşimin" mutluluk için vazgeçilmez bir eşik olduğu, "ayrımcılık algısının" ise bireyleri doğrudan mutsuzluk sınıfına iten en baskın negatif bariyer olduğu veri bilimi teknikleriyle doğrulanmıştır. Bu çalışma, karmaşık sosyal olguların istatistiksel algoritmalarla nasıl profesyonel ve objektif bir şekilde açıklanabileceğini ortaya koymaktadır.

2. GİRİŞ

Toplumsal refahın ve entegrasyonun en önemli göstergelerinden biri, göçmen statüsündeki bireylerin bulundukları ülkedeki genel mutluluk düzeyleridir. Geleneksel araştırmalar bu durumu sıklıkla betimsel istatistiklerle açıklarken; bu projede Avrupa Sosyal Araştırması (ESS) verileri temel alınarak, "mutluluk" kavramı denetimli makine öğrenmesi (supervised learning) algoritmaları üzerinden öngörülebilir bir veri bilimi problemine dönüştürülmüştür. Çalışma kapsamında, yönlendirilmiş grup çalışmaları dersi boyunca öğrenilen tüm sınıflandırma yöntemleri tek bir projede entegre edilmiş; göçmenlerin mutluluğu üzerinde etkili olan faktörlerin hem istatistiksel ağırlıkları hem de sosyolojik etkileri algoritmaların çıktılarıyla nesnel bir şekilde kanıtlanmıştır.

2.1. Çalışmanın Amacı ve Kapsamı

Bu çalışmanın temel amacı; Avrupa Sosyal Araştırması (ESS) verilerinden hareketle, Avrupa genelinde yaşayan göçmenlerin genel mutluluk durumlarını etkileyen demografik, sosyo-ekonomik ve algısal faktörleri denetimli makine öğrenmesi algoritmalarıyla modellemek ve bireylerin hangi durumlarda "mutlu" veya "mutsuz" sınıfında yer alacağını yüksek doğrulukla tahmin etmektir.

Çalışmanın teknik amacı ise ders süresince işlenen Lojistik Regresyon, Karar Ağaçları (CART), Random Forest, Gradient Boosting Machines (GBM), XGBoost ve LightGBM gibi sınıflandırma algoritmalarının performanslarını; veri ön işleme, boyut indirgeme (PCA, LDA, PLS) ve model açıklanabilirliği (SHAP, PDP) süreçleri dahilinde karşılaştırmalı olarak analiz etmektir.

Kapsam açısından araştırma; Avrupa Sosyal Araştırması'nın ilgili veri toplama dalgasına katılan ve göçmen statüsünde olan bireylerin verilerini içermektedir. Bireylerin yaş, cinsiyet gibi demografik özelliklerinin yanı sıra toplumsal güven, maruz kalınan ayrımcılık algısı, sağlık durumu ve gelir yeterliliği gibi çok yönlü parametreler modelin öznitelik uzayını oluşturmaktadır.

2.2. Veri Setinin Kaynağı ve Manipülasyon Süreci

Çalışmada kullanılan veriler, Avrupa genelinde metodolojik olarak en yüksek örneklem kalitesine sahip, çok uluslu bir yüz yüze anket çalışması olan Avrupa Sosyal Araştırması (European Social Survey - ESS) veri tabanından derlenmiştir. ESS, toplumsal eğilimleri, algıları ve kurumsal güveni ölçmede uluslararası düzeyde kabul görmüş bilimsel bir kaynaktır.

Ham veri setinin analiz edilebilir ve denetimli öğrenme modellerine uygun bir yapıya kavuşturulması için şu manipülasyon süreçleri gerçekleştirilmiştir:

- **Filtreleme ve Subset Oluşturma:** Ham veri seti içerisinde yalnızca ilgili ülkelerde doğmamış veya ebeveynlerinden en az biri yabancı ülke doğumlu olan "göçmen/göçmen kökenli" katılımcılar filtrelenerek analize özel bir alt veri seti yapılandırılmıştır.
- **Hedef Değişken Tasarımı:** Orijinal veri setinde 0-10 skalasında sürekli/sıralı olarak yer alan genel mutluluk ölçeği, makine öğrenmesi sınıflandırma algoritmalarının

binary (ikili) çıktı üretebilmesi için belirli bir istatistiksel kesim noktası (eşik değeri) üzerinden 0 (Mutsuz) ve 1 (Mutlu) şeklinde kodlanmıştır.

- **Öznitelik Mühendisliği ve Temizlik:** Analiz dışı bırakılması gereken gözlemler düzenlenmiş, eksik veri analizi öncesinde değişkenlerin R ortamındaki veri tipleri (faktör, numerik, sıralı faktör) algoritmaların matematiksel altyapılarına uygun olacak şekilde dönüştürülmüştür.

3. VERİ SETİ VE DEĞİŞKEN TANIMLARI

	Mutluluk	Yerlesim_Tipi	Yas	Cinsiyet	Egitim_Yili	Gelir_Duzeyi	Toplumsal_Guven	Saglik_Durumu	Sosya
1	10	4	33	1	12	10	10	1	
2	5	1	72	1	14	3	4	3	
3	10	2	81	2	13	3	5	1	
4	5	3	18	2	11	6	6	2	
5	6	4	64	2	10	2	4	3	
6	2	3	23	1	12	2	2	1	
7	4	1	25	1	18	1	3	3	
8	5	5	49	2	20	3	3	2	
9	6	1	47	1	11	3	5	3	
10	10	1	71	2	13	2	6	2	
11	5	1	65	2	6	2	2	3	
12	10	4	32	2	11	5	6	3	
13	10	4	48	2	12	2	4	1	
14	5	4	72	1	12	2	3	3	

Modelleme ve istatistiksel çıkarım süreçlerinin sağlıklı bir şekilde yürütülebilmesi, veri setini oluşturan bileşenlerin ve bu bileşenlerin matematiksel yapılarının doğru tanımlanmasına bağlıdır. Bu bölümde, analize dahil edilen hedef değişken ile bu değişkeni açıklamak üzere seçilen bağımsız değişkenlerin (özniteliklerin) yapısal özellikleri ele alınmıştır.

3.1. Hedef Değişken ve Sınıflandırma Mantığı

Çalışmanın bağımlı değişkeni, katılımcıların genel iyi oluş hallerini yansıtan "Mutluluk" düzeyidir. Avrupa Sosyal Araştırması (ESS) kapsamında bu veri, katılımcılara yöneltilen "Her şeyi hesaba kattığınızda, bütün olarak ne kadar mutlusunuz?" sorusuna verilen cevaplardan oluşmaktadır. Orijinal ölçekte bu değişken, 0 (Aşırı Mutsuz) ile 10 (Aşırı Mutlu) arasında değişen 11 basamaklı sıralı (ordinal) bir metrikle ölçülmüştür.

Denetimli öğrenme literatüründeki sınıflandırma (classification) algoritmalarının (Lojistik Regresyon, Karar Ağaçları, Rastgele Orman ve Boosting türevleri) optimizasyon ve hata fonksiyonlarının etkin çalışabilmesi adına bu yapı ikili (binary) bir formata dönüştürülmüştür. Bu doğrultuda belirlenen istatistiksel kesim noktasına göre;

- 0 ile 5 (dahil) arasındaki puanlar "**Mutsuz / Düşük Mutluluk**" (0),
- 6 ile 10 arasındaki puanlar ise "**Mutlu / Yüksek Mutluluk**" (1)

olarak kodlanmıştır. Bu ikili sınıflandırma mantığı, sadece tahmin modellerinin duyarlılık (sensitivity) ve özgüllük (specificity) metriklerinin net bir şekilde hesaplanmasını sağlamakla kalmamış; aynı zamanda göçmen bireyleri risk grubuna (mutsuzluk sınıfına) iten sistemik ve yapısal dinamiklerin lojistik olasılıklar üzerinden analiz edilmesine zemin hazırlamıştır.

3.2. Sayısal ve Kategorik Öznitelikler

Hedef değişkendeki varyansı ve sınıfsal ayrımı açıklamak üzere model mimarisine dahil edilen bağımsız değişkenler, R programlama ortamındaki veri tiplerine ve algoritmaların (mesafe, varyans veya bölme tabanlı) çalışma prensiplerine uygun olarak iki ana grupta sınıflandırılmıştır:

Kategorik (Nitel) Öznitelikler:

- **Cinsiyet (Faktör):** Bireylerin demografik cinsiyet beyanı. Lojistik regresyon ve kural bazlı ağaçlarda kırılma noktaları oluşturmada temel referanslardan biridir.
- **Eğitim Durumu (Sıralı Faktör):** Katılımcıların tamamladıkları en yüksek eğitim kademesi (Düşük, Orta, Yüksek). Sosyo-ekonomik hareketliliğin bir göstergesi olarak modele dahil edilmiştir.
- **Yerleşim Yeri Türü (Faktör):** Bireyin yaşadığı bölgenin kırsal alan, kasaba veya büyük şehir/metropol olma durumu. Sosyal ağlara erişim ve izolasyon seviyelerini kontrol etmek amacıyla kullanılmıştır.
- **Gelir Yeterlilik Algısı (Sıralı Faktör):** Hane halkı toplam gelirinin mevcut yaşam standartlarını karşılama düzeyine dair sübjektif algı (Aşırı zorlanıyor, İdare ediyor, Rahat yaşıyor).
- **Sağlık Durumu (Sıralı Faktör):** Bireyin genel sağlık durumunu nasıl değerlendirdiği

Sayısal (Nicel / Sürekli) Öznitelikler:

- **Yaş (Numeric):** Katılımcıların analizin yapıldığı dönemdeki kronolojik yaşı. Yaş ile mutluluk arasındaki olası non-lineer (U-eğrisi vb.) ilişkilerin yakalanması açısından önem arz eder.
- **Toplumsal Güven Skoru (Numeric):** Bireylerin genel olarak insanlara, ülkedeki adalet sistemine ve kurumlara duyduğu güveni temsil eden, 0-10 skalasından türetilmiş sürekli indeks skoru.
- **Sosyal Etkileşim Sıklığı (Numeric):** Arkadaş, aile veya iş çevresiyle sosyal amaçlı buluşma, görüşme ve ortak faaliyetlerde bulunma sıklığını gösteren metrik veri.
- **Ayrımcılık Algısı (Numeric):** Bireyin ırk, din, dil, milliyet veya göçmenlik statüsü nedeniyle toplumsal düzlemde maruz kaldığını hissettiği dışlanma ve ayrımcılığın şiddetini ölçen sürekli değişken. Modellerin değişken önem derecesi (Gini / Gain) analizlerinde en yüksek ayırt edici güce sahip özniteliklerden biridir.

Seçilen bu öznitelik matrisi, sosyal bir olgu olan göçmen mutluluğunun hem yapısal (gelir, eğitim) hem de psikososyal (güven, ayrımcılık) boyutlarını eksiksiz şekilde temsil edecek biçimde yapılandırılmıştır.

4. VERİ ÖN İŞLEME SÜREÇLERİ

Ham verinin doğrudan algoritmalara verilmesi, modelin yanlı (biased) sonuçlar üretmesine veya algoritma yakınsamasının başarısız olmasına neden olabilir. Bu çalışmada, model performansını maksimize etmek ve istatistiksel çıkarımların güvenilirliğini sağlamak amacıyla iki kritik ön işleme adımı uygulanmıştır.

4.1. Eksik Veri Analizi ve KNN Imputation Uygulaması

Veri setinde yer alan eksik gözlemler (NA), istatistiksel modellemenin en önemli handikaplarından biridir. Bu projede eksik verilerin doldurulması aşamasında rastgele silme yöntemi yerine, verinin orijinal yapısını koruyan "imputation" (atama) teknikleri tercih edilmiştir. Bu kapsamda üç farklı yöntem (Ortalama/Medyan Atama, KNN Imputation ve MissForest) arasında bir performans yarışı gerçekleştirilmiştir.

Doldurma yöntemi seçilirken temel kriter, doldurulmuş verinin standart sapmasının, orijinal verinin standart sapmasına (varyansına) en yakın kalması olarak belirlenmiştir. Yapılan analizler sonucunda:

- **Ortalama/Medyan Atama:** Verideki varyansı yapay olarak düşürdüğü ve dağılımı merkezde topladığı için elenmiştir.
- **MissForest:** Rastgele orman tabanlı güçlü bir yöntem olsa da, mevcut veri setinde KNN kadar doğal bir yakınlık sergilememiştir.
- **KNN Imputation (K-En Yakın Komşu):** Eksik değere sahip bir gözlemi, ona en yakın "k" sayıdaki komşusunun (Öklid mesafesi baz alınarak) özelliklerine göre doldurması sayesinde verinin orijinal standart sapmasına en yakın sonuçları üretmiştir.

Bu bilimsel gerekçe doğrultusunda, **KNN Imputation** "en iyi yöntem" olarak seçilmiş ve veri setindeki bilgi kaybı minimize edilerek veri bütünlüğü sağlanmıştır.

	Orijinal_SD	Baseline_SD	KNN_SD	MissForest_SD
Mutluluk	2.762	2.762	2.762	2.762
Yas	16.840	16.803	16.831	16.806
Egitim_Yili	3.629	3.629	3.629	3.629
Toplumsal_Guven	2.363	2.363	2.363	2.363
Ulkede_Gecirilen_Yil	21.679	21.538	21.555	21.551
Hayat_Memnuniyeti	3.014	3.014	3.014	3.014
Gocun_Ekonomik_Algisi	3.264	3.264	3.264	3.264
Gocun_Kulturel_Algisi	3.297	3.297	3.297	3.297

4.2. Veri Ölçeklendirme: Z-Score Standartlaştırması ve Bilimsel Gerekçesi

Veri setinde yer alan öznel özelliklerin farklı ölçü birimlerine sahip olması, özellikle mesafe tabanlı algoritmaların ve boyut indirgeme yöntemlerinin sonuçlarını domine edebilir. Algoritmaların tüm değişkenlere eşit ağırlıkta yaklaşabilmesi için verilerin ölçeklendirilmesi zorunludur.

```
> summary(df_knn_zscore$Yas)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-2.17048 -0.74452 -0.03153  0.00000  0.85970  1.98859
> summary(df_knn_minmax$Yas)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 0.0000  0.3429  0.5143  0.5219  0.7286  1.0000
> summary(df_knn_robust$Yas)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-1.33333 -0.44444  0.00000  0.01966  0.55556  1.25926
```

Ölçeklendirme sürecinde Standartlaştırma (Z-Score), Min-Max ve Robust Scaler yöntemleri karşılaştırılmış; nihai karar **Z-Score Standartlaştırması** yönünde olmuştur. Bu seçimin bilimsel gerekçeleri şunlardır:

1. **Boyut İndirgeme Uyumu:** Analizimizin ilerleyen safhalarında kullanılan PCA (Temel Bileşenler Analizi) ve LDA (Doğrusal Ayırıştırma Analizi), değişkenlerin sıfır merkezli ve eşit varyanslı olmasını gerektirir. Z-Score, her bir veriyi ortalamadan çıkarıp standart sapmaya bölerek bu gereksinimi tam olarak karşılar.
2. **Katsayı Yorumlanabilirliği:** Lojistik Regresyon gibi modellerde katsayıların (beta değerleri) "standart sapma birimi" üzerinden yorumlanmasına olanak tanır. Bu da farklı ölçekteki değişkenlerin (Yaş vs. Toplumsal Güven) hedef değişken üzerindeki etkisinin elmalarla elmaların kıyaslanması gibi adil bir şekilde yapılmasını sağlar.
3. **Uç Değer Esnekliği:** Veri setinin sosyal bir anket olması ve doğal varyansı içermesi nedeniyle, veriyi 0-1 arasına sıkıştıran Min-Max yerine, dağılımın şeklini bozmadan merkeze çeken Z-Score tercih edilmiştir.

Bu işlemler sonucunda tüm değişkenler ortak bir istatistiksel zemine taşınmış ve modellerin saf veri üzerinden en yüksek doğruluğa ulaşması için gerekli altyapı tamamlanmıştır.

5. DENETİMLİ ÖĞRENME MODELLEMELERİ


Bu bölümde, ders kapsamında teorik olarak ele alınan ve uygulama sürecinde veri setine adapte edilen tüm denetimli öğrenme algoritmaları, başlangıç seviyesinden ileri seviye topluluk yöntemlerine kadar sistematik bir hiyerarşiyle sunulmuştur.

5.1. Lojistik Regresyon

Lojistik Regresyon, bu çalışmanın "baseline" (temel) modeli olarak kurgulanmıştır. Hedef değişkenin ikili (binary) yapıda olması nedeniyle, bağımsız değişkenlerin bir bireyi "Mutlu" (0) veya "Mutsuz" (1) sınıfına dahil etme olasılığını Sigmoid fonksiyonu üzerinden hesaplamaktadır.

Degisken	Odds_Ratio
(Intercept)	0.742
Yas	1.598
Cinsiyet	0.636
Egitim_Yili	0.981
Gelir_Duzeyi	1.175
Toplumsal_Guven	1.616
Saglik_Durumu	1.499
Sosyal_Etkilesim	1.727
Ayrimcilik_Algisi	0.606
Ulkede_Gecirilen_Yil	0.869
Gocun_Ekonomik_Algisi	1.087
Gocun_Kulturel_Algisi	1.389
Guvenlik_Hissi	1.175

Model Performansı ve ROC Analizi: Analiz sonuçlarına göre modelin ürettiği **AUC (Eğri Altındaki Alan) değeri 0.858** olarak hesaplanmıştır. İstatistiksel literatürde 0.80 üzerindeki AUC değerleri "iyi", 0.85 üzerindikiler ise "çok iyi/mükemmel" sınıflandırma gücü olarak kabul edilir. Elde edilen 0.858'lik skor, modelin göçmenlerin mutluluk durumlarını ayırt etmede oldukça yüksek bir tahmin gücüne sahip olduğunu ve duyarlılık (sensitivity) ile özgüllük (specificity) arasındaki dengeyi başarıyla kurduğunu kanıtlamaktadır.



Hata Matrisi (Confusion Matrix) Değerlendirmesi: Modelin tahmin başarısını test verisi üzerinden incelediğimizde şu sonuçlar elde edilmiştir:

- **Doğru Negatif (TN - Mutlu):** 22 birey doğru tahmin edilmiştir.
- **Doğru Pozitif (TP - Mutsuz):** 12 birey doğru tahmin edilmiştir.
- **Hatalı Tahminler:** 5 birey hatalı şekilde mutsuz (FP), 7 birey ise hatalı şekilde mutlu (FN) olarak sınıflandırılmıştır. Genel tablo, modelin "Mutlu" olan grubu ayırt etmede "Mutsuz" gruba oranla bir adım daha başarılı olduğunu göstermektedir.

İstatistiksel ve Sosyolojik Çıkarımlar: Lojistik regresyonun katsayı (beta) analizleri, özniteliklerin yönü ve şiddeti hakkında şu kritik bulguları ortaya koymuştur:

```
Call:
glm(formula = Mutluluk_Durumu ~ ., family = binomial, data = train_scaled)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   -0.29816    0.17151  -1.738  0.08213 .
Yas             0.46900    0.28230   1.661  0.09664 .
Cinsiyet      -0.45276    0.18321  -2.471  0.01346 *
Egitim_Yili   -0.01880    0.18837  -0.100  0.92050
Gelir_Duzeyi   0.16131    0.18464   0.874  0.38231
Toplumsal_Guven 0.47997    0.19662   2.441  0.01464 *
Saglik_Durumu  0.40506    0.20884   1.940  0.05243 .
Sosyal_Etkilesim 0.54656    0.18373   2.975  0.00293 **
Ayrımcılık_Algisi -0.50142    0.20306  -2.469  0.01353 *
Ülkede_Gecirilen_Yil -0.14044    0.26443  -0.531  0.59535
Gocun_Ekonomik_Algisi 0.08315    0.23173   0.359  0.71974
Gocun_Kulturel_Algisi 0.32845    0.23358   1.406  0.15969
Güvenlik_Hissi  0.16168    0.19042   0.849  0.39583
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)


    Null deviance: 250.10  on 181  degrees of freedom
Residual deviance: 205.52  on 169  degrees of freedom
AIC: 231.52

Number of Fisher Scoring iterations: 4
```

- Cinsiyet Faktörü:** Model çıktılarında kadınların "1" (Mutsuzluk) sınıfına dahil olma olasılığının erkeklere oranla istatistiksel olarak daha yüksek olduğu saptanmıştır. Bu bulgu, göç sürecinde kadınların karşılaştığı ek zorlukların veya ev içi dinamiklerin mutluluk üzerindeki baskılayıcı etkisine işaret etmektedir.
- Sosyal Etkileşim ve Güven:** Sosyal etkileşim sıklığı ve toplumsal güven puanı arttıkça, bireyin "0" (Mutlu) sınıfında yer alma olasılığı anlamlı şekilde artmaktadır. Bu iki değişken, model için adeta bir "mutluluk eşiği" görevi görmektedir.
- Ayrımcılık Bariyeri:** "Mutsuz" grubun ayrımcılık algısı dağılımının çok daha geniş ve yüksek olması, bu değişkenin mutsuzluk için en belirgin risk faktörü olduğunu doğrulamıştır.

Lojistik Regresyon sonuçları, veri setindeki ilişkilerin büyük ölçüde doğrusal bir mantıkla açıklanabildiğini göstermiş ve daha karmaşık modeller için güçlü bir referans noktası oluşturmuştur.

Sınıflar Arası Profil Farkı ve Karakterizasyon Analizi



Modelin tahmin ettiği sınıflara ait veri dağılımları görselleştirildiğinde, öznelitliklerin sınıflar üzerindeki ayrıştırıcı etkisi istatistiksel olarak şu şekilde tespit edilmiştir:

- Sosyal Etkileşim ve Toplumsal Güven:** "Mutlu" olarak sınıflandırılan gözlem grubuna ait medyan (ortanca) değerlerinin, sosyal etkileşim ve güven düzeylerinde "Mutsuz" grubuna kıyasla istatistiksel olarak belirgin şekilde daha yüksek bir eksende kümелendiği saptanmıştır. Bu durum, güçlü bir sosyal ağı sahip olmanın ve yüksek kurumsal/bireysel güvenin, göçmenlerin genel mutluluk haline erişmesinde kritik bir 'eşik değeri' işlevi gördüğünü göstermektedir.
- Ayrımcılık Algısı:** Diğer taraftan ayrımcılık algısı değişkeni incelendiğinde; "Mutsuz" olarak kategorize edilen grubun varyansının ve veri dağılım aralığının genişleyerek çok daha yüksek değerlerde yoğunlaştığı (kuyruklandığı) görülmektedir. Bu istatistiksel dağılım asimetrisi, yüksek ayrımcılık algısının göçmenleri doğrudan 'mutsuzluk' sınıfına iten en dominant (baskın) risk faktörü olduğunu doğrulamaktadır.

Temel Sınıflandırma Başarı Metrikleri ve İstatistiksel Yorumu:

--- Lojistik Regresyon Performans Raporu ---		
	Metrik	Değer
1	Accuracy	0.7391
2	Precision	0.7059
3	Sensitivity	0.6316
4	Specificity	0.8148
5	F1-Score	0.6667
6	Kappa	0.4535
7	AUC	0.8580


Hata matrisinden elde edilen değerler üzerinden modelin sınıflandırma performansını ölçen temel metrikler hesaplanmış ve sonuçlar şu şekilde yorumlanmıştır:

- **Doğruluk (Accuracy) - %73.9:** Modelin genel olarak test setindeki gözlemlerin yüzde kaçını doğru sınıflandırdığını gösterir. Elde edilen %73.9'luk oran, sosyal bilimler verilerindeki yüksek varyans (insan davranışının tahmindeki zorluğu) göz önüne alındığında oldukça tatminkâr bir genel başarı seviyesidir.
- **Kesinlik (Precision) - %70.6:** Modelin "Mutsuz" (1) olarak tahmin ettiği bireylerin ne kadarının gerçekten mutsuz olduğunu gösterir. Başka bir deyişle, modelin alarm verdiği her 100 vakadan yaklaşık 71'i doğru tespit edilmiştir. Bu metrik, yanlış alarmların (yanlış mutsuzluk tahminlerinin) düşük tutulabildiğini kanıtlar.
- **Duyarlılık (Recall / Sensitivity) - %63.2:** Gerçekte "Mutsuz" olan göçmenlerin yüzde kaçının model tarafından doğru bir şekilde yakalanabildiğini ifade eder. Görece düşük olan bu oran, sistemik ayrımcılık veya güvensizlik nedeniyle mutsuz olan bazı bireylerin model tarafından tam yakalanamadığını ve "Mutlu" sınıfına karıştığını göstermektedir.
- **Özgüllük (Specificity) - %81.5:** Gerçekte "Mutlu" olan bireylerin doğru sınıflandırılma oranıdır. %81.5'lik yüksek skor, modelin "Mutlu" grubu tanımada çok daha istikrarlı ve güvenilir çalıştığını doğrulamaktadır.
- **F1-Skoru - %66.7:** Kesinlik ve Duyarlılık metriklerinin harmonik ortalamasıdır. Veri setindeki olası sınıf dengesizliklerini (Mutlu ve Mutsuz sayılarının eşit olmaması durumu) dikkate alarak modelin gerçek gücünü gösteren bu skor, Lojistik Regresyonun dengeli ve genellenebilir bir yapı kurduğunu teyit etmektedir.
- **Kappa İstatistiği ve Gerçek Güvenilirlik** Modelin sınıflandırma performansını yalnızca Accuracy (Doğruluk) üzerinden değerlendirmek, veri setindeki olası yığılmalar nedeniyle yanıltıcı olabilmektedir. Bu nedenle, modelin tahmin başarısının "rastlantısal uyumdan" (chance agreement) ne kadar arındırıldığını ölçmek amacıyla Cohen's Kappa istatistiği hesaplanmıştır. Lojistik Regresyon modelinin Kappa değeri **0.45** olarak bulunmuştur. Bu değer, modelin elde ettiği yüksek doğruluk oranının şans eseri olmadığını; bağımsız değişkenlerin (ayrımcılık, güven vb.) hedef değişkeni açıklamada istatistiksel olarak anlamlı ve güvenilir bir ayrıştırma gücüne sahip olduğunu kanıtlamaktadır.

5.2. Karar Ağaçları (CART)

Lojistik Regresyonun değişkenler arasındaki doğrusal ilişkileri olasılıksal olarak modellediği aşamadan sonra, verideki daha karmaşık ve hiyerarşik yapıları çözmek amacıyla **CART (Sınıflandırma ve Gerileme Ağaçları)** algoritması uygulanmıştır. Lojistik Regresyon "X değişkeni arttıkça mutluluk olasılığı ne kadar artar?" sorusuna yanıt ararken; CART algoritması "Hangi koşullar birleştğinde birey mutlu veya mutsuz olur?" sorusuna net kural setleri (If-Else yapıları) ile yanıt vermektedir.


Modelin Mantığı ve Kural Setlerinin Çıkarımı: Algoritma, veri setini en yüksek bilgi kazancını (Information Gain) sağlayacak şekilde dallara ayırarak bir karar mekanizması oluşturmuştur. Ağacın en ucundaki kutucuklar (yapraklar), sadece kesin bir sınıf tahmini (0 veya 1) sunmakla kalmamış, aynı zamanda o dala düşen bireylerin "**Mutluluk Olasılığını**" da ortaya koymuştur. Örneğin, belirli bir kural dizisinden geçen bir yaprakta "0.85" değerinin okunması, o profil özelliklerine sahip bir göçmen grubunun %85 ihtimalle "Mutlu" sınıfında yer aldığını kanıtlamaktadır. Bu özellik, politika yapıcılar için risk gruplarını (mutsuzluk olasılığı yüksek olanlar) tespit etmede stratejik bir kolaylık sağlamaktadır.



Öne Çıkan Profil: "İdeal Uyum" (High Social & Low Discrimination) Karar ağacının dallanma yapısı incelendiğinde, mutluluk sınıfı için en kısa ve en güçlü yolun; **Yüksek Sosyal Etkileşim** ve **Düşük Ayrımcılık Algısı** kombinasyonundan geçtiği görülmüştür. Bu kural seti, sosyal sermayesi güçlü olan ve dışlanma hissetmeyen bireylerin, diğer değişkenlerden bağımsız olarak en yüksek mutluluk skoruna ulaştığını doğrulamaktadır.

Aşırı Öğrenme (Overfitting) Kontrolü ve Pruning (Budama) Süreci: Karar ağaçlarının en büyük dezavantajı olan "eğitim verisini ezberleme" (overfitting) riskini bertaraf etmek amacıyla **Complexity Parameter (CP)** analizi gerçekleştirilmiştir. CP grafiği üzerinden

yapılan deęerlendirmede, modelin en dūřuk apraz doęrulama hatasını (cross-validation error) verdięi optimum aęa derinlięi belirlenmiřtir. Bu analiz sonucunda aęa "budanarak" (pruning), modelin karmařıklıęı ile genellenebilirlięi arasındaki hassas denge kurulmuř ve modelin yeni gelen verilere karřı tutarlılıęı artırılmıřtır.



CART Performans Deęerlendirmesi: Modelin hata matrisi (Confusion Matrix) zerinden elde edilen sonular řu řekildedir:

- **Gerek Mutlu (TN):** 18 birey doęru tahmin edilmiřtir.
- **Gerek Mutsuz (TP):** 11 birey doęru tahmin edilmiřtir.
- **Hatalı Tahminler:** 6 adet Yanlıř Pozitif (FP) ve 11 adet Yanlıř Negatif (FN) gzlemlenmiřtir.

Sınıflandırma Metriklerinin Kavramsal erevesi ve CART Modeli Performans Analizi:

--- CART Performans Raporu ---		
	Metrik	Deęer
1	Accuracy	0.6304
2	Precision	0.6471
3	Sensitivity	0.5000
4	Specificity	0.7500
5	F1-Score	0.5641
6	Kappa	0.2524
7	AUC	0.7008

Modelin hata matrisi (Confusion Matrix) zerinden elde edilen sonular istatistiksel bařarı metrikleri baęlamında řu řekilde deęerlendirilmiřtir:

- **Doęruluk (Accuracy) - ~%63:** Modelin toplamda yaptıęı doęru tahminlerin (gerek mutlu ve gerek mutsuz), tm veri setine oranıdır. CART modelinde yaklařık %63 olarak hesaplanan bu oran, modelin genel ynelimleri yakalayabildięini gsterse de doęrusal modellerin gerisinde kalmıřtır.
- **Duyarlılık / Hassasiyet (Sensitivity / Recall) - %50.0:** Gerekte "Mutsuz" (1) sınıfında yer alan bireylerin, model tarafından yzde ka oranında doęru tespit

edildiğini ölçer. CART modelinde bu oranın %50 (11/22) seviyesinde kalması; modelin mutsuz göçmenleri yakalamada zorlandığını ve bu grubun yarısını (11 Yanlış Negatif) hatalı şekilde "Mutlu" sınıfına atadığını (Tip II Hata) göstermektedir.


- **Özgüllük (Specificity) - %75.0:** Gerçekte "Mutlu" (0) olan bireylerin doğru sınıflandırılma kabiliyetidir. %75'lik bu oran, kural tabanlı karar ağacının "Mutlu" profili tanımlamada ve ayırt etmede istatistiksel olarak daha kararlı ve başarılı çalıştığını doğrulamaktadır.
- **Kesinlik (Precision) - %64.7:** Modelin "Mutsuz" olarak işaretlediği ve alarm verdiği bireylerin gerçekte ne kadarının mutsuz olduğunu ifade eder. %64.7'lik skor, modelin "mutsuz" dediği durumlarda nispeten güvenilir olduğunu, ancak yanlış alarmların (Yanlış Pozitif) oranının da dikkate alınması gerektiğini belirtir.
- **F1-Skoru - ~%56.4:** Duyarlılık ve Kesinlik metriklerinin harmonik ortalamasını alarak, veri setindeki olası sınıf dengesizliklerine karşı modelin "gerçek dayanıklılığını" gösteren özet metriktir. Lojistik regresyona kıyasla daha düşük çıkan bu F1-Skoru, karar ağaçlarının esnek yapısının varyansı artırdığını ve ağaç budama (pruning) işlemine rağmen genellenebilirliğin sınırlı kaldığını kanıtlamaktadır.
- **Kappa İstatistiği:** Kural bazlı ağaç yapısının sınıfları tahmin ederken şans faktörünü ne ölçüde ekarte edebildiğini görmek amacıyla CART modeli için de Cohen's Kappa skoru incelenmiş 0.25 olarak hesaplanmıştır. Bu skor, modelin genel doğruluk oranının ötesinde, yaprak düğümlerdeki (leaf nodes) ayrışmanın gerçek bir istatistiksel dayanağı olup olmadığını göstermektedir. Lojistik regresyon ile kıyaslandığında elde edilen bu Kappa değeri, karar ağaçlarının katı (if-else) yapısının veri setindeki varyansa karşı ne kadar direnç gösterebildiğini ve rastlantısal uyumu aşmada hangi seviyede kaldığını objektif olarak ortaya koymaktadır.

5.3. Random Forest


Karar ağaçlarının (CART) en büyük kısıtı olan yüksek varyans ve aşırı öğrenme (overfitting) riskini minimize etmek amacıyla, çalışmanın bu aşamasında topluluk öğrenmesi (ensemble learning) algoritmalarından biri olan Random Forest (Rastgele Orman) modeli uygulanmıştır. Tek bir karar ağacının ürettiği katı kurallar yerine, Bootstrap Aggregating (Bagging) yöntemiyle yüzlerce farklı ağaç oluşturulmuş ve bu ağaçların çoğunluk oyu (majority voting) ile nihai sınıflandırma kararına varılmıştır.

Topluluk Öğrenmesine Geçiş ve Modelin Mantığı: CART algoritması veri setindeki gürültüye (noise) karşı hassasken ve veriyi ezberlemeye meyilliyken, Random Forest hem satırları (gözlemleri) hem de sütunları (öznitelikleri) rastgele seçerek birbirinden bağımsız ağaçlar üretir. Bu sayede modelin genellenebilirliği artırılmış ve göçmenlerin mutluluk tahminlerindeki varyans (sapma) istatistiksel olarak düşürülmüştür.

Out-Of-Bag (OOB) Hata Analizi ve İçsel Doğrulama: Random Forest algoritmasının veri bilimi literatüründeki en büyük avantajlarından biri, harici bir test setine veya çapraz doğrulamaya (cross-validation) ihtiyaç duymadan kendi içsel doğrulamasını yapabilmesidir. Algoritma eğitilirken, her bir ağaç için orijinal veri setinin yaklaşık üçte ikisi (bootstrap sample) kullanılırken, dışarıda kalan üçte birlik kısım (Out-of-Bag - Torba Dışı) o ağacın test edilmesi için kullanılmıştır.



Değişken Önem Dereceleri Modelin sunduğu en değerli analitik çıktılarından biri, "Gini Importance" (Gini Safsızlığındaki Ortalama Düşüş) analizidir. Bu analiz, bir değişkenin ağaçların dallanma sürecinden çıkarılması durumunda modelin tahmin doğruluğunun ve sınıfları (Mutlu/Mutsuz) ayrıştırma gücünün ne kadar azalacağını matematiksel olarak hesaplar.




Analiz sonuçlarına göre:

- **Sosyal Etkileşim ve Toplumsal Güven:** Modelin düğümlerinde (nodes) sınıfları saflaştırmada en yüksek Gini düşüşüne neden olan (en yüksek önem skoruna sahip) öznitelikler olarak zirvede yer almıştır.
- **Ayrimcilik Algısı:** Hedef değişken üzerindeki ayırıcı gücüyle sıralamada bu değişkenleri hemen takip etmiş ve mutsuzluk sınıfını izole etmedeki kritik rolünü korumuştur.
- **Demografik vs. Psikososyal Faktörler:** Yaş, eğitim veya cinsiyet gibi katı demografik değişkenlerin, Gini sıralamasında algısal değişkenlerin (güven, etkileşim, ayrimcilik) gerisinde kalması; göçmenlerin genel mutluluğunu belirleyen temel dinamiklerin psikososyal entegrasyon faktörleri olduğunu objektif veriyle ispatlamaktadır.

Doğrusal Olmayan İlişkiler ve Marjinal Etki Analizi (PDP)

Modelin hedef değişkeni tahmin ederken değişkenlerle nasıl bir ilişki kurduğunu incelemek amacıyla Partial Dependence Plot (PDP) grafikleri oluşturulmuştur. Lojistik regresyondaki katılım modelimiz gereği y-ekseni "Mutsuzluk Olasılığını (Logit)" temsil ettiğinden, grafikte eğrinin aşağı inmesi o faktörün **mutluluğu artırdığını** göstermektedir:



- **Toplumsal Güven ve Sosyal Etkileşim (Doygunluk Etkisi):** Her iki değişkenin eğrisi incelendiğinde, düşük seviyelerden orta seviyelere doğru geçişte mutluluk üzerinde çok hızlı ve dik bir pozitif etki (aşağı yönlü sert düşüş) yaşandığı görülmektedir. Ancak belli bir seviyeden (örneğin sosyal etkileşimde 5 birimden) sonra eğri yataylaşarak bir "doygunluk noktasına" (saturation point) ulaşmaktadır. Bu durum sosyolojik olarak; sosyalleşmenin ve güvenin mutluluk için "olmazsa olmaz" kritik bir eşik olduğunu, ancak bu eşik aşıldıktan sonraki ek artışların marjinal faydasının giderek azaldığını kanıtlar.
- **Ayrımcılık Algısı (Sert Bariyer):** Sosyal etkileşim ve güvenin aksine, ayrımcılık algısı grafiği hiçbir kırılma veya doygunluk noktası barındırmayan, tamamen doğrusal ve yukarı yönlü (mutsuzluğu kesintisiz artıran) bir seyir izlemektedir. Bu grafik, ayrımcılığın göçmen mutluluğunun önündeki en katı, en keskin ve sürekli negatif bariyer olduğunu istatistiksel olarak teyit etmektedir.


İstatistiksel Çıkarım: Random Forest, CART modeline kıyasla varyansı düşürüp tahmin kararlılığını artırırsa da, genel doğruluk (Accuracy) oranlarında Lojistik Regresyon ile oldukça benzer bir performans sergilemiştir. Bu istatistiksel sonuç çok kritik bir gerçeğe işaret eder: Veri setindeki öznitelikler ile göçmen mutluluğu arasındaki ilişki mimarisi, ağaç tabanlı karmaşık if-else kurallarından ziyade, lojistik eğrilerle açıklanabilen "doğrusal eğilimli" bir yapıya (linear tendency) çok daha yakındır.

```
--- Random Forest Performans Raporu ---
      Metrik  Deger
1  Accuracy 0.7174
2  Precision 0.5294
3  Sensitivity 0.6429
4  Specificity 0.7500
5  F1-Score 0.5806
6  Kappa 0.3705
7  AUC 0.7972
```

5.4. Gradient Boosting Machines (GBM)


Ağaç tabanlı topluluk modellerinde (ensemble) varyansı düşüren Random Forest'in ardından, modelin "hatalardan öğrenme" (boosting) performansını ölçmek amacıyla Gradient Boosting Machines (GBM) algoritması uygulanmıştır.

Model Optimizasyonu (Best Iteration): GBM'in eğitim verisini ezberlemesini (overfitting) engellemek için öğrenme eğrisi (Learning Curve) analiz edilmiştir. Eğitim ve çapraz doğrulama (cross-validation) hatalarının optimum noktada kesiştiği ağaç sayısı tespit edilerek, modelin en yüksek genellenebilirlik kapasitesine ulaştığı "En İyi İterasyon" (Best Iteration) seviyesinde eğitim durdurulmuştur.



Friedman'ın H-İstatistiği ve Sinerjik Etkileşim: Sosyal bilimler verilerinde değişkenler bağımsız hareket etmez. GBM'in en büyük avantajı olan değişkenler arası "etkileşim şiddeti", Friedman'ın H-İstatistiği (H-Statistic) ile ölçülmüştür. Analiz sonucunda, **Sosyal Etkileşim** ve **Toplumsal Güven** arasında istatistiksel olarak yüksek bir sinerji bulunmuştur. Bu durum; hem sosyalleşen hem de sisteme güvenen bir göçmenin mutlu olma olasılığının, bu iki değişkenin tek başlarına yaptıkları etkinin toplamından çok daha büyük olduğunu matematiksel olarak kanıtlar.


Etkileşim Isı Haritası (Heatmap) Analizi:



Bu sinerji, iki boyutlu Partial Dependence (PDP) ısı haritalarıyla görselleştirilmiştir. Haritada, her iki değişkenin aynı anda yükseldiği bölgelerde mutluluk olasılığı eksponansiyel olarak zirveye çıkarken; sadece birinin yüksek olduğu durumlarda (örn: sosyalleşen ama güvenmeyen birey) mutluluk oranının sınırlı bir "bariyeri" aşmadığı net bir şekilde gözlemlenmiştir. Bu bulgu, göçmen mutluluğunun yalnızca sosyal etkinliklerle değil, kurumsal güvenin inşasıyla eşzamanlı sağlanabileceğini ortaya koymaktadır.

GBM Değişken Etkileri ve Yön Analizi

GBM modelinin eğitim sürecinde hata fonksiyonunu (loss function) en çok azaltan öznitelikleri ve bu özniteliklerin mutluluk üzerindeki yönsel etkilerini (pozitif/negatif) gösteren grafik incelendiğinde oldukça çarpıcı yapısal bulgular elde edilmiştir.



- Entegrasyon Yorgunluğu (En Güçlü Negatif Etki):** Analizdeki en dikkat çekici bulgu; modeldeki en belirleyici faktör olan 'Ülkede Geçirilen Yıl' değişkeninin mutluluk üzerinde güçlü bir negatif etkiye sahip olmasıdır. Değişken önem sıralamasında zirvede yer alan bu durum sosyolojik olarak; göçmenlerin ülkede kaldıkları süre uzadıkça karşılanmayan beklentilerin veya "entegrasyon yorgunluğunun" mutsuzluğu şiddetli bir biçimde tetiklediğini işaret etmektedir.
- Pozitif İtici Güçler:** Buna karşın 'Yaş', 'Toplumsal Güven' ve 'Sosyal Etkileşim', göçmen mutluluğunu en çok artıran temel pozitif itici güçler olarak öne çıkmaktadır. Grafikteki yeşil barların büyüklüğü, güçlü sosyal bağlar kurmanın ve sisteme güven

duymanın mutluluk için ne kadar hayati birer kalkan olduğunu istatistiksel olarak doğrulamaktadır.

- **Eğitim Paradoksu:** Sıralamada dikkat çeken bir diğer unsur, 'Eğitim Yılı' değişkeninin mutluluk üzerinde negatif bir etki yaratmasıdır. Bu istatistiksel sonuç, göç edilen ülkede eğitim seviyesi arttıkça niteliğe uygun istihdam bulamama (statü kaybı veya beyin göçü hüsranı) gibi faktörlerin bireyleri mutsuzluğa ittiğini destekler niteliktedir.

GBM Performans Metrikleri ve İstatistiksel Değerlendirme

GBM modelinin test verisi üzerinde ürettiği performans raporu incelendiğinde, "hatalardan öğrenme" (boosting) mimarisinin önceki doğrusal ve sığ ağaç modellerine kıyasla sınıflandırma gücünü belirgin şekilde artırdığı tespit edilmiştir. Elde edilen istatistiksel metriklerin analizi şu şekildedir:

--- GBM Performans Raporu ---		
	Metrik	Değer
1	Accuracy	0.7609
2	Precision	0.7059
3	Sensitivity	0.6667
4	Specificity	0.8214
5	F1-Score	0.6857
6	Kappa	0.4930
7	AUC	0.8742


- **AUC (Eğri Altındaki Alan) - 0.8742:** GBM modelinin ulaştığı 0.874'lük AUC skoru, Lojistik Regresyon (0.858) modelini geride bırakarak, algoritmanın "Mutlu" ve "Mutsuz" grupları birbirinden ayırt etme (discrimination) kapasitesinin mükemmele yakın bir seviyeye ulaştığını matematiksel olarak kanıtlamaktadır.
- **Doğruluk (Accuracy) - %76.09:** Model, test verisetindeki gözlemlerin yaklaşık %76.1'ini doğru sınıflandırmıştır. Sosyal bilimlerdeki yüksek varyans göz önüne alındığında, bu oran oldukça tatminkâr bir genel isabetliliği ifade eder.
- **Duyarlılık (Sensitivity) - %66.67:** Modelin en kritik başarılarından biri, gerçekte "Mutsuz" (Sınıf 1) olan bireyleri doğru yakalama oranını %66.7'ye çıkarmasıdır. CART modelinde %50 bandında kalan bu metriğin yükselmesi; boosting algoritmasının, doğrusal modellerin gözden kaçırdığı karmaşık profilleri ve zor tespit edilen mutsuz göçmenleri yakalamada çok daha yetkin olduğunu göstermektedir.
- **Özgüllük (Specificity) - %82.14:** Gerçekte "Mutlu" (Sınıf 0) olan bireylerin %82.1'i doğru sınıflandırılmıştır. Model, risk grubunu (mutsuzları) daha iyi yakalarken, aynı zamanda mutlu profili tanımlamadaki istikrarlı ve güvenilir yapısını korumayı başarmıştır.
- **Kesinlik (Precision) ve F1-Skoru:** Modelin mutsuz olduğuna dair alarm verdiği her 100 durumun 70.6'sında (0.7059) haklı çıkması, yanlış alarmların (Tip I Hata) düşük olduğunu kanıtlar. Kesinlik ve duyarlılık arasındaki ideal dengeyi yansıtan **F1-Skorunun 0.6857** seviyesine çıkması, sınıflar arası dağılım dengesizliğine karşı modelin direncinin yüksek olduğunu doğrular.
- **Cohen's Kappa Skoru - 0.4930:** Modelin ulaştığı yüksek doğruluk oranının veri setindeki yığılmalardan veya şans eseri rastlantılardan (chance agreement) kaynaklanmadığını gösteren Kappa değeri 0.49 olarak hesaplanmıştır. Bu oran, modelin verideki değişkenler arasındaki sinerjiyi gerçeğe dayalı, istatistiksel olarak anlamlı bir şekilde modellediğini teyit etmektedir.

Nihai Değerlendirme: GBM algoritması; yüksek AUC değeri, dengeli sınıflandırma yeteneği ve şaştan arındırılmış güvenilirliği ile varyans ve yanlılık (bias-variance) açmazını başarıyla aşmış ve projenin en iddialı ve analitik derinliği en yüksek modellerinden biri olmuştur.

5.5. XGBoost

Standart GBM mimarisinin üzerine inşa edilen ve "L1/L2 düzenlileştirme" (regularization) teknikleriyle aşırı öğrenmeye karşı çok daha dirençli olan **XGBoost (Extreme Gradient Boosting)** algoritması, projenin tahmin kapasitesini optimize etmek amacıyla uygulanmıştır.


Öğrenme Eğrisi (Learning Curve) ve Optimizasyon:



XGBoost modelinin performans gelişimi, iterasyon bazlı öğrenme eğrileri üzerinden analiz edilmiştir. Eğitim hatasının (Siyah Çizgi) sürekli azalmasına karşın, çapraz doğrulama hatasının (Yeşil Çizgi) minimuma indiği ve ardından yükselme eğilimi gösterdiği nokta "**Best Iteration**" (Mavi Kesikli Çizgi) olarak belirlenmiştir. Bu analiz, modelin veriyi ezberlemesini (overfitting) engelleyerek, gerçek dünya verileri üzerindeki en yüksek AUC performansına (yaklaşık 100. iterasyonda) ulaştığını kanıtlamaktadır.

Gain (Kazanç) Metriği ile Değişken Hiyerarşisi Analizi


Elde edilen Gain ve Etki Yönü grafiği incelendiğinde, klasik modellerin aksine ezber bozan bir hiyerarşi ortaya çıkmıştır:



- **Entegrasyon Yorgunluğunun Zirvesi:** Modeli ayrıştırmada açık ara en yüksek bilgi kazancını sağlayan değişken "**Ülkede Geçirilen Yıl**" olmuştur ve etkisi belirgin bir şekilde **negatiftir**. Bu istatistiksel durum, göçmenlerin hedef ülkede kaldıkları süre uzadıkça beklentilerin karşılanamaması veya entegrasyon yorgunluğu nedeniyle mutsuzluğun tetiklendiğini güçlü bir şekilde kanıtlamaktadır.
- **Demografik ve Sosyal Pozitif Güçler:** İkinci sırada model başarısına en yüksek katkıyı sağlayan değişken "**Yaş**" olmuş ve etkisi **pozitif** olarak ölçülmüştür. Hemen ardından sırasıyla "Toplumsal Güven", "Sosyal Etkileşim" ve "Göçün Kültürel Algısı" pozitif itici güçler olarak sıralamada yer alarak, ileri yaştan ve güçlü sosyal bağların mutluluğa giden temel anahtarlar olduğunu doğrulamıştır.
- **Eğitim Paradoksu:** Grafikte "Eğitim Yılı" değişkeninin mutluluğa **negatif** etki etmesi (kırmızı bar), göçmen bireylerin eğitim seviyeleri arttıkça niteliklerine uygun iş bulamamalarından (statü kaybı/beyin göçü hüsrarı) kaynaklanan yapısal bir mutsuzluğu istatistiksel olarak gözler önüne sermektedir.

SHAP (Shapley Additive Explanations) ile Bireysel Yönel Etkiler


Modelin ürettiği makro kararları bireysel düzeyde (mikro) açıklamak amacıyla, oyun teorisine dayanan ileri bir analitik yöntem olan SHAP analizi uygulanmıştır. SHAP grafiğinde renkler özneliliğin sayısal değerini (Sarı/Turuncu = Yüksek, Mor = Düşük) temsil ederken; yatay eksen (SHAP value), gözlemin hangi sınıfa itildiğini (Negatif değerler = Sınıf 0/Mutlu, Pozitif değerler = Sınıf 1/Mutsuz) gösterir.



Grafik detaylı olarak incelendiğinde şu kritik yönelimler tespit edilmiştir:

- **Güven ve Etkileşimin Çekim Kuvveti:** 'Toplumsal Güven' ve 'Sosyal Etkileşim' değişkenleri için yüksek değerlere sahip bireyler (grafikteki sarı ve turuncu noktalar), dikey eksenin sol tarafına (negatif SHAP değerlerine) doğru güçlü bir yığılma göstermektedir. Bu matematiksel eğilim, sosyalleşen ve sisteme güvenen göçmenlerin model tarafından net bir şekilde **"Mutlu"** sınıfına çekildiğini kanıtlar.
- **Ayrımcılık Algısındaki Ters Kodlama Mantığı:** Veri setinin anket yapısı gereği ayrımcılık algısı sorusuna (1=Evet uğradım, 2=Hayır uğramadım) verilen yanıtlarda; yüksek sayısal değere (Sarı renk = Ayrımcılık hissetmeyenler) sahip bireylerin grafiğin soluna (Mutlu sınıfına) yığıldığı görülmektedir. Tam aksine, ayrımcılığa uğradığını hissedenler (Mor noktalar = Düşük sayısal kodlama), sağ tarafa (SHAP > 0) itilerek doğrudan **"Mutsuz"** olarak sınıflandırılmıştır.
- **Süre Uzadıkça Artan Risk:** SHAP grafiğinde 'Ülkede Geçirilen Yıl' değişkeninin yüksek olduğu durumlar (sarı noktalar), 0 çizgisinin sağına (Mutsuzluk bölgesine) doğru tehlikeli bir saçılım göstermektedir. Bu bireysel dağılım, Gain grafiğindeki "süre uzadıkça mutsuzluğun artması" (negatif etki) bulgusunu nokta atışıyla teyit etmektedir.

Öğrenme Eğrisi (Learning Curve) ve Optimizasyon



XGBoost modelinin iterasyon sayısına (eklenen ağaç sayısına) bağlı olarak AUC performansının gelişimini gösteren öğrenme eğrisi incelendiğinde; modelin ilk 50-100 iterasyonda çok hızlı bir öğrenme ivmesi yakalayarak AUC değerini hızla yukarı taşıdığı görülmektedir. Eğrinin yaklaşık 100. iterasyondan itibaren dalgalanarak yatay bir seyir (plateau) izlemeye başlaması, modelin veri setindeki örüntüleri yeterince öğrendiğini, aşırı öğrenmeye (overfitting) düşmeden performans açısından ideal doygunluk noktasına ulaştığını kanıtlamaktadır.

XGBoost Performans Metrikleri ve İstatistiksel Değerlendirme

Modelin test verisi üzerindeki metrikleri incelendiğinde, XGBoost'un özellikle "risk grubunu" yakalamada çok üstün bir denge kurduğu tespit edilmiştir:


--- XGBoost Performans Raporu ---		
	Metrik	Değer
1	Accuracy	0.7826
2	Precision	0.6471
3	Sensitivity	0.7333
4	Specificity	0.8065
5	F1-Score	0.6875
6	Kappa	0.5218
7	AUC	0.7525

- **Doğruluk (Accuracy) - %78.26:** Model, test setindeki gözlemlerin %78.3'ünü doğru sınıflandırarak oldukça yüksek ve tatminkâr bir genel isabetliliğe ulaşmıştır.
- **Duyarlılık (Sensitivity) - %73.33:** Modelin en büyük başarısı, gerçekte "Mutsuz" (Sınıf 1) olan bireyleri yakalama oranını %73.3'e çıkarmasıdır. Bu oran, mutsuz göçmenleri tespit etmede önceki modellerin (CART, Lojistik vb.) çok ilerisinde bir kapasiteyi temsil eder.
- **Özgüllük (Specificity) - %80.65:** Risk grubunu (mutsuzları) yüksek oranda yakalarken, "Mutlu" (Sınıf 0) profili doğru tanımlama istikrarından (%80.6) da taviz vermemiştir.
- **Kappa (0.5218) ve F1-Skoru (0.6875):** 0.52 seviyesine çıkan Cohen's Kappa skoru, bu yüksek tahmin başarısının kesinlikle şans eseri (rastlantısal) olmadığını; yaklaşık %69 bandındaki F1-Skoru ise modelin sınıf dengesizliklerine karşı ne kadar dirençli ve güvenilir olduğunu istatistiksel olarak tescillemektedir. (Genel AUC skoru: 0.7525)

5.6. LightGBM: Kalibrasyon Eğrisi ve Nihai Performans

Projenin şampiyon modeli olarak öne çıkan **LightGBM (Light Gradient Boosting Machine)**, yaprak odaklı (leaf-wise) büyüme stratejisi ve yüksek hız/doğruluk dengesi sayesinde hem doğrusal olmayan karmaşık ilişkileri yakalamış hem de en kararlı sınıflandırma performansını üretmiştir.

Kalibrasyon Eğrisi (Calibration Curve) Güvenilirlik Analizi



Modelin ürettiği olasılıkların teorik birer sayıdan ibaret olmadığını doğrulamak adına Kalibrasyon Eğrisi analizi gerçekleştirilmiştir. Eğrinin 45 derecelik kırmızı ideal referans çizgisine yakınlığı, model tahminlerinin "gerçek hayatla" tam anlamıyla kalibre olduğunu gösteren nihai sağlamadır. Grafikteki siyah noktalı çizginin bu ideal çizgi etrafında seyretmesi modelin tutarlılığını kanıtlamaktadır.

Örneğin; geliştirilen LightGBM modeli belirli bir göçmen profili grubu için "%60 ihtimalle mutludur" şeklinde bir olasılık ürettiğinde, gerçek veriye dönüp bakıldığında o gruptaki bireylerin sahadaki gerçek mutluluk oranının da yaklaşık %60 olduğu gözlemlenmektedir. Bu yüksek uyum, analizin sadece laboratuvar ortamında değil, gerçek dünya parametrelerinde de yüksek güvenilirliğe sahip olduğunu tescilleyen en temel metriktir.

LightGBM Hata Matrisi ve Nihai Başarı Değerlendirmesi

Modelin test verisi üzerindeki nihai hata matrisi (Confusion Matrix) incelendiğinde, elde edilen sınıflama kararlılığı şu şekildedir:


- **Doğru Negatif (TN - Gerçek Mutlu):** 25 birey kusursuz şekilde doğru sınıflandırılmıştır.
- **Doğru Pozitif (TP - Gerçek Mutsuz):** 13 birey risk grubunda (mutsuz sınıfında) olarak doğru tahmin edilmiştir.
- **Hatalı Tahminler (FP / FN):** Yalnızca 4 birey hatalı pozitif (FP), 4 birey ise hatalı negatif (FN) olarak sınıflandırılmıştır.

Bu matris değerleri, LightGBM'in hem mutlu sınıfını tanımada hem de yakalanması en zor olan mutsuz risk grubunu ayırt etmede projedeki tüm algoritmalarından daha dengeli ve üstün

bir performans sergilediğini göstermektedir. Tip I ve Tip II hata oranlarını (4'er vakaya) eş zamanlı olarak düşürebilmesi, modelin genellenebilirlik başarısını matematiksel olarak doğrulamaktadır.

Değişken Önemi (Gain) ve Etki Yönü Analizi

LightGBM modelinin karar ağaçlarını oluştururken özniteliklerin sağladığı "Gain" (Bilgi Kazancı) ve bunların mutluluk üzerindeki etki yönlerini (Direction) gösteren grafik incelendiğinde, göçmen mutluluğunun temel dinamiklerine dair çok net bir hiyerarşi ortaya çıkmaktadır:



- **Pozitif Çekim Merkezleri:** Modelin tahmin gücüne en yüksek katkıyı sağlayan ilk iki değişken sırasıyla '**Sosyal Etkileşim**' ve '**Toplumsal Güven**' olmuştur ve her ikisinin de etkisi **pozitiftir** (Yeşil bar). Bu durum, aktif sosyalleşmenin ve kurumsal güvenin mutluluk için en güçlü iki temel taşı olduğunu doğrular. Üçüncü sırada yer alan '**Gelir Düzeyi**', sosyo-ekonomik refahın pozitif itici bir güç olduğunu istatistiksel olarak kanıtlamaktadır.
- **Negatif Bariyerler ve Entegrasyon Yorgunluğu:** Modelde mutluluğu negatif yönde etkileyen (kırmızı bar) en güçlü öznitelik '**Ülkede Geçirilen Yıl**' olarak tespit edilmiştir. Bu durum, hedef ülkede geçirilen süre uzadıkça "entegrasyon yorgunluğunun" veya karşılanmayan beklentilerin mutsuzluğu doğrudan körüklediğini teyit eder. Bunu takip eden '**Ayrımcılık Algısı**' ve '**Eğitim Yılı**' (eğitim seviyesi arttıkça artan statü uyumsuzluğu hüsrarı) göçmenlerin önündeki en belirgin negatif bariyerler olarak modeldeki yerini almıştır.

LightGBM Performans Metrikleri ve İstatistiksel Değerlendirme

LightGBM modelinin test verisi üzerindeki analitik metrikleri, algoritmanın neden projenin "Şampiyon Modeli" unvanını aldığını matematiksel olarak kanıtlamaktadır:

```
--- LightGBM Performans Raporu ---
Metrik  Deger
1  Accuracy 0.8478
2  Precision 0.7059
3  Sensitivity 0.8571
4  Specificity 0.8438
5  F1-Score 0.7742
6  Kappa 0.6611
7  AUC 0.8986
```

Kusursuz Denge (Sensitivity ve Specificity): Modelin en çarpıcı başarısı, gerçekte "Mutsuz" (Sınıf 1) olan bireyleri yakalama oranı olan **Duyarlılık (Sensitivity) değerini %85.71'e** (0.8571) fırlatmasıdır. Önceki modellerin yakalamakta zorlandığı bu "risk grubunu" %86'ya yakın bir başarıyla tespit ederken, mutlu bireyleri tanıma kararlılığını (**Özgüllük - %84.38**) da eşzamanlı olarak çok yüksek tutmuştur.

Doğruluk (Accuracy) ve AUC: %84.78'lik genel doğruluk oranı ve **0.8986'lık AUC skoru** (yaklaşık 0.90), modelin mutlu ve mutsuz sınıfları birbirlerinden ayırt etme (discrimination) kapasitesinin "mükemmel" sınırına ulaştığını gösterir.

Kappa ve F1-Skoru: Sınıf dengesizliklerine karşı modelin sağlamlığını gösteren F1-Skorunun **0.7742'ye** ulaşması, Kesinlik (Precision) ve Duyarlılık arasındaki o zorlu optimum dengeyi sağladığını kanıtlar. **0.6611** seviyesindeki yüksek Cohen's Kappa skoru ise bu performansın şans eseri olmadığını, verideki varyansın model tarafından gerçek anlamda çözüldüğünü istatistiksel olarak tescillemektedir.

6. BOYUT İNDİRGEME ÖNCESİ EN İYİ MODEL SEÇİMİ

Çalışmanın bir sonraki aşaması olan boyut indirgeme (PCA, LDA, PLS-DA) süreçlerine geçmeden önce; orijinal veri seti (saf değişken uzayı) üzerinde eğitilen tüm denetimli öğrenme algoritmalarının performansları toplu olarak karşılaştırılmış ve projenin referans modeli belirlenmiştir. Modellerin Accuracy (Doğruluk), F1-Skoru ve AUC (Eğri Altındaki Alan) metriklerini içeren genel karşılaştırma tablosu incelendiğinde şu istatistiksel sonuçlara ulaşılmıştır:

	Model	Accuracy	F1	AUC
6	LightGBM	0.8478	0.7742	0.8986
4	GBM	0.7609	0.6857	0.8742
1	Log. Regresyon	0.7391	0.6667	0.8580
3	Random Forest	0.7174	0.5806	0.7972
5	XGBoost	0.7826	0.6875	0.7525
2	CART	0.6304	0.5641	0.7008

- **LightGBM'in Mutlak Üstünlüğü (Şampiyon):** %84.78 Doğruluk, 0.7742 F1-Skoru ve 0.8986 AUC değeri ile LightGBM, tüm metriklerde diğer modelleri açık ara geride bırakmıştır. Model, ağaç tabanlı yapısıyla (leaf-wise) verideki karmaşık doygunluk noktalarını ve doğrusal olmayan ilişkileri en iyi öğrenen algoritma olarak şampiyonluğunu ilan etmiştir.
- **Boosting Algoritmalarının Genel Başarısı:** Sıralamada LightGBM'i takip eden standart GBM (0.8742 AUC) ve XGBoost (%78.26 Accuracy); "hatalardan öğrenme" (boosting) mimarisinin, sosyal anket verilerindeki yüksek varyansı ve değişkenler arası sinerjiyi çözmedeki tartışmasız gücünü kanıtlamıştır.
- **Lojistik Regresyonun Şaşırtıcı Direnci:** Projenin temel (baseline) modeli olan Lojistik Regresyon (0.858 AUC); karmaşık yapıları Random Forest (0.797 AUC) ve CART (0.700 AUC) modellerini geride bırakarak şaşırtıcı derecede güçlü bir performans sergilemiştir. Bu tablo, "Ayrımcılık Algısı" gibi hayati değişkenlerin hedef üzerindeki etkisinin son derece doğrusal (lineer) bir yapıda olduğunu ispatlamaktadır.
- **CART ve Random Forest'ın Sınırları:** Tekil bir karar ağacı olan CART %63'lük doğrulukla en zayıf model olurken, varyansı düşürülmüş Random Forest modeli

%71.74'te kalmıştır. Bu durum, katı if-else kurallarına dayanan standart ağaç yapılarının, sosyal verilerdeki istisnaları yakalamada yetersiz kaldığını göstermektedir.


Sonuç olarak; saf verinin içerdiği tüm sosyolojik ve demografik bilgiyi en az hata payıyla öğrenen **LightGBM**, boyut indirgeme yöntemlerinin (PCA vb.) veriye vereceği olası tahribatı test edeceğimiz bir sonraki aşama için referans şampiyon model olarak seçilmiştir.

7. BOYUT İNDİRGEME YÖNTEMLERİ VE KARŞILAŞTIRMA (PCA, LDA, PLS-DA)

Çalışmanın bu aşamasında, orijinal veri setindeki değişken sayısını (boyutunu) azaltarak modellerin karmaşıklığını düşürmek ve olası çoklu doğrusal bağlantı (multicollinearity) sorunlarını gidermek amacıyla çeşitli boyut indirgeme teknikleri uygulanmıştır. Ancak sosyal verilerin yapısı gereği, bu algoritmaların "bilgi koruma" kapasiteleri ile şampiyon modelimiz LightGBM'in "saf veri" üzerindeki performansı karşılaştırıldığında kritik metodolojik bulgular elde edilmiştir.

7.1. PCA (Temel Bileşenler Analizi) ve Bilgi Kaybı Değerlendirmesi

Gözetimsiz bir boyut indirgeme yöntemi olan PCA (Principal Component Analysis) uygulanarak verideki varyans analiz edilmiştir. Analiz sonucunda, elimizdeki verinin taşıdığı toplam bilginin (varyansın) %85'ini koruyabilmek için değişken uzayının 8 temel bileşene (Principal Component) indirilmesi gerektiği saptanmıştır.



Model	Type	Accuracy	F1	Kappa	AUC
LR	PCA	0.717	0.606	0.386	0.809
CART	PCA	0.543	0.512	0.117	0.523
RF	PCA	0.717	0.606	0.386	0.791
GBM	PCA	0.717	0.581	0.371	0.728
XGB	PCA	0.739	0.684	0.466	0.759
LGB	PCA	0.761	0.718	0.516	0.838

Boyut indirgenmiş bu yeni veri seti üzerinden tüm modeller tekrar eğitilmiş ve en başarılı yöntemin yine LightGBM olduğu görülmüştür. Ancak, PCA uygulanan LightGBM modelinin performansı, orijinal (saf) değişkenlerle kurulan LightGBM modelinin performansıya

karşılaştırıldığında belirgin bir düşüş kaydetmiştir. Bu durumun istatistiksel ve sosyolojik gerekçeleri şu şekildedir:

- **Hayati Eşiklerin Yok Olması:** Mutluluk gibi sosyal olgular doğrusal (lineer) ilerlemez; önceki bölümlerdeki PDP analizlerinde kanıtlandığı üzere belirli eşiklerde doygunluğa ulaşır. PCA gibi yöntemler, veriyi zorunlu olarak doğrusal eksenlere sıkıştırarak bu hayati kırılma noktalarını (örneğin sosyal etkileşimin doygunluk eşiğini) matematiksel olarak düzleştirmiş ve yok etmiştir.
- **Değişken Safiyetinin Seyrelmesi:** "Ayrımcılık Algısı" gibi hedefe doğrudan ve keskin bir şekilde etki eden yapısal değişkenlerin gücü, PCA dönüşümü sırasında diğer değişkenlerle harmanlanarak yapay bileşenler (PC1, PC2 vb.) içinde seyretilmiş ve modelin bu net sinyalleri okuması engellenmiştir.

7.2. LDA ve PLS-DA Yaklaşımları

Gözetimsiz PCA'nın bilgi kaybına neden olması üzerine, hedef değişkeni (Mutlu/Mutsuz) dikkate alan gözetimli (supervised) boyut indirgeme yöntemleri olan LDA (Lineer Diskriminant Analizi) ve PLS-DA (Kısmi En Küçük Kareler Diskriminant Analizi) algoritmaları da test edilmiştir. Bu yöntemler sınıflar arası mesafeyi maksimize etmeye çalışsa da, temelde "doğrusal" (linear) birer dönüşüm olmaları nedeniyle, ağaç tabanlı LightGBM'in kendi iç mekanizmasıyla bulduğu o karmaşık, doğrusal olmayan (if-else) sınırları yakalamada yine yetersiz kalmışlardır.

	Model	Veri_Tipi	Accuracy	F1	Kappa	AUC
1	LR	LDA	0.761	0.667	0.480	0.852
5	XGB	LDA	0.761	0.686	0.493	0.834
6	LGB	LDA	0.717	0.649	0.415	0.833
2	CART	LDA	0.674	0.615	0.340	0.826
4	GBM	LDA	0.652	0.579	0.288	0.796
3	RF	LDA	0.739	0.684	0.466	0.790

	Model	Veri_Tipi	Accuracy	F1	Kappa	AUC
4	GBM	PLS-DA	0.783	0.706	0.533	0.866
1	LR	PLS-DA	0.696	0.611	0.362	0.844
3	RF	PLS-DA	0.739	0.647	0.440	0.840
6	LGB	PLS-DA	0.783	0.722	0.545	0.836
5	XGB	PLS-DA	0.696	0.588	0.347	0.811
2	CART	PLS-DA	0.739	0.684	0.466	0.797

Boyut İndirgeme vs. Doğal Özellik Seçimi (Feature Selection)

Analizler sonucunda, boyut indirgeme (PCA, LDA, PLS-DA) uygulanmamış, orijinal değişken uzayında eğitilen LightGBM kesin ve tartışmasız şampiyon model olarak tescillenmiştir. Gradient Boosting tabanlı algoritmalar (LightGBM, XGBoost), ağaçları büyütürken bilgi kazancını (Gain) maksimize eden değişkenleri kendi iç mekanizmasıyla (doğal özellik seçimi) zaten otomatik olarak filtrelemektedir. Dışarıdan zorlamalı bir boyut küçültme işlemi yapmak, modele fayda sağlamaktan ziyade yapısal bilgi kaybına yol açmıştır.

Metodolojik Çıkarım: Karmaşık sosyal anket verilerini makine öğrenmesiyle analiz ederken, değişkenlerin "saf hikayesini" ve orijinal formunu korumak, çoğu zaman boyutu küçültmekten (matematiksel sıkıştırmadan) çok daha değerlidir. Teori ile pratik, veri bilimi algoritmalarının orijinal veri üzerindeki eşsiz gücüyle doğrulanmıştır.

8. BOYUT İNDİRGEME SONRASI EN İYİ MODELİN SEÇİLMESİ

Orijinal değişken uzayında eğitilen ve herhangi bir boyut indirgeme yöntemi (PCA, LDA, PLS-DA) uygulanmayan **LightGBM** modeli projenin nihai şampiyonu olarak tescillenmiştir. Boyut indirgenmiş verilerle kurulan modellerin daha düşük performans göstermesi ve saf LightGBM modelinin zirvede yer alması şu analitik gerekçelere dayanmaktadır:

- **Doğruluk ve Esneklik Dengesi (Non-Linear Yapı):** Mutluluk gibi karmaşık sosyal olgular doğrusal bir düzlemde ilerlememekte, belirli kırılma noktalarında doygunluğa ulaşmaktadır. PCA gibi yöntemler veriyi doğrusal eksenlere sıkıştırarak bu hayati eşikleri yok ederken, LightGBM karar ağacı yapısı ve yaprak odaklı büyüme stratejisiyle bu non-lineer dinamikleri kusursuzca korumuştur.
- **Doğal Öznitelik Seçimi ve Saf Bilgi:** Gradient Boosting algoritmaları, ağaçları büyütürken bilgi kazancını (Gain) maksimize eden değişkenleri kendi iç mekanizmasıyla otomatik olarak seçer. Harici bir boyut indirgeme işlemi uygulamak, "Ayrımcılık Algısı" gibi doğrudan hedefi etkileyen saf ve güçlü değişkenlerin etkisini yapay bileşenler içinde seyrelterek bilgi kaybına yol açmıştır.

9. SONUÇ VE TARTIŞMA

Proje kapsamında yürütülen tüm modelleme ve ileri analitik süreçler, hem veri bilimi metodolojisi açısından hem de sosyal politika çıkarımları açısından hayati sonuçlar ortaya koymuştur.

9.1. Metodolojik Çıkarımlar

Karmaşık sosyal anket verilerini analiz ederken, değişkenlerin yapay eksenlere sıkıştırılması yerine "saf hikayesinin" ve orijinal formunun korunmasının boyutu küçültmekten çok daha değerli olduğu ampirik olarak kanıtlanmıştır. Teori ile pratik, makine öğrenmesi algoritmalarının orijinal veri üzerindeki gücüyle tam bir uyum yakalamıştır.

9.2. Sosyolojik Bulgular ve Politika Önerileri

- **Sosyal Etkileşim Eşiği:** Model analizleri, sosyal etkileşimin göçmen mutluluğunun en temel itici gücü olduğunu ancak bir "doygunluk noktası" barındırdığını göstermektedir. Belirli bir sosyalleşme frekansına ulaşıldıktan sonra elde edilen marjinal fayda azalarak yataylaşmaktadır. Bu nedenle uyum politikalarında niceliksel faaliyetlerden ziyade niteliksel sosyal ağların inşasına odaklanılmalıdır.
- **Sistemik Ayrımcılık Bariyeri:** Bireyin kendini dışlanmış hissetmesi ve ayrımcılığa uğrama algısı, modelleri doğrudan "mutsuzluk" sınıflandırmasına iten en baskın risk faktörüdür. Göçmen entegrasyonuna yönelik makro politikalarda bu yapısal ve algısal bariyer ortadan kaldırılmadığı sürece genel mutluluk düzeyinde kalıcı bir iyileşme sağlamak istatistiksel olarak mümkün görünmemektedir.

10. KAYNAKÇA

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794.

European Social Survey (ESS). (2024). *ESS Round 10/11 Data: European Social Survey Source Questionnaire and Data Files*. Bergen: Sikt - Norwegian Agency for Shared Services in Education and Research.

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 1189-1232.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer Science & Business Media.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146-3154.

Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765-4774.

R Core Team. (2023). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. URL: <https://www.R-project.org/>.